

Artigos de Referência

LLM-Driven Data Generation and a Novel Soft Metric for Evaluating Text-to-SQL in Aviation MRO

P Sutanto, J Kenrick, M Lorenz, J Santoso

arXiv preprint arXiv:2506.13785, 2025• <https://arxiv.org/pdf/2506.13785>

Citado por 1

EVOLVE: Evaluation of Language-to-SQL Validity and Effectiveness-A Detailed Review Framework for Complex Text-to-SQL Queries

R Katikeri, ANR Pepakayala, L Kuncham, R Barla, K Tarun, S Charan, A Vaid

2024 IEEE International Conference on Big Data (BigData), 2024•

<https://ieeexplore.ieee.org/document/10825883>

Citado por 3

Text-to-SQL: A methodical review of challenges and models

AB Kanburoğlu, FB Tek

Turkish Journal of Electrical Engineering and Computer Sciences,

2024•<https://journals.tubitak.gov.tr/cgi/viewcontent.cgi?article=4077&context=elektrik>

Citado por 44

Metrics and Benchmarks for Evaluating Dutch Prompt-Based Text-to-SQL Systems

R Raaij - 2025 - studenttheses.uu.nl

https://studenttheses.uu.nl/bitstream/handle/20.500.12932/49754/MscThesis_LLMSQL_RubenvRaaij_final_draftv3.pdf?sequence=1&isAllowed=y

Citado por 0

1. Métricas de Execução e Estado (Database State)

EX (Execution Accuracy):

Define-se pela identidade estrita entre os conjuntos de resultados: $EX = R_{pred} = R_{gold}$.

É uma métrica binária que não tolera variações na ordenação (a menos que especificado) ou na cardinalidade.

$$EX(R_{pred}, R_{gold}) = I(R_{pred} \equiv R_{gold})$$

Soft Execution F1:

Aborda a avaliação como um problema de *Information Retrieval*. Em vez de binária, calcula a média harmônica entre Precision (P) e Recall (R) sobre as tuplas retornadas. (LLM-Driven Data Generation and a Novel Soft Metric for Evaluating Text-to-SQL in Aviation MRO)

$$P = \frac{|T_{pred} \cap T_{gold}|}{|T_{pred}|}, \quad R = \frac{|T_{pred} \cap T_{gold}|}{|T_{gold}|}$$

$$Soft F_1 = \begin{cases} \frac{2 \cdot P \cdot R}{P + R}, & \text{se } P + R > 0 \\ 0, & \text{se } P + R = 0 \end{cases}$$

Valid Efficiency Score (VES):

Mede o custo computacional relativo. Se $EX = 1$, então $VES = \text{Cost}(\text{SQL}_{\text{gold}})/\text{Cost}(\text{SQL}_{\text{pred}})$. É fundamental para avaliar a viabilidade de consultas em bancos de dados de produção (Big Data), mas não avalia corretude. (EVOLVE: Evaluation of Language-to-SQL Validity and Effectiveness-A Detailed Review Framework for Complex Text-to-SQL Queries)

$$VES(R_{\text{pred}}, R_{\text{gold}}) = I(EX = 1) \cdot \left(\frac{t_{\text{gold}}}{\max(t_{\text{pred}}, \epsilon)} \right)$$

Statistical Summarization:

Emprega momentos estatísticos para validar a distribuição dos dados. Compara vetores de propriedades μ , σ^2 de colunas numéricas entre R_{pred} e R_{gold} , sendo resiliente a variações de ordenação que a EX pura penalizaria. (EVOLVE: Evaluation of Language-to-SQL Validity and Effectiveness-A Detailed Review Framework for Complex Text-to-SQL Queries)

$$\text{Stats} = I(\forall i \in M, |\mu_{\text{pred},i} - \mu_{\text{gold},i}| \leq \theta \wedge |\sigma_{\text{pred},i} - \sigma_{\text{gold},i}| \leq \theta)$$

Similarity Scoring:

Calculada através da distância de Jaccard entre os conjuntos de colunas e linhas retornados, quantificando a sobreposição informacional entre os espaços vetoriais dos resultados. (EVOLVE: Evaluation of Language-to-SQL Validity and Effectiveness-A Detailed Review Framework for Complex Text-to-SQL Queries)

$$J(S_{\text{pred}}, S_{\text{gold}}) = \frac{|S_{\text{pred}} \cap S_{\text{gold}}|}{|S_{\text{pred}} \cup S_{\text{gold}}|}$$

2. Métricas Estruturais e Sintáticas**LFA (Logical Form Accuracy):**

Equivalência estrita de string. É a métrica mais conservadora, pois ignora a invariância de projeção e a comutatividade de operadores lógicos no SQL. (Text-to-SQL: A methodical review of challenges and models)

$$LFA(s_{\text{pred}}, s_{\text{gold}}) = I(\text{norm}(s_{\text{pred}}) = \text{norm}(s_{\text{gold}}))$$

EM (Exact Match Accuracy):

Diferente da LFA, o EM geralmente opera sobre subconjuntos da AST. Verifica se os componentes (SELECT, WHERE, GROUP BY) possuem os mesmos elementos, independentemente da ordem textual. (Text-to-SQL: A methodical review of challenges and models)

CM (Component Match):

Decompõe a SQL em módulos. Atribui scores individuais para a precisão de *Schema Linking* (colunas/tabelas) e *Operator Selection* (JOINS, agregações).

$$CM(s_{pred}, s_{gold}) = \frac{1}{|K^*|} \sum_{k \in K^*} \frac{|P_k \cap G_k|}{|P_k \cup G_k|}$$

Levenshtein Correctness (LeCo):

Baseia-se na distância de edição $d(s_1, s_2)$ entre as strings. Fornece um gradiente de proximidade textual que auxilia na identificação de erros tipográficos simples em nomes de colunas. (Metrics and Benchmarks for Evaluating Dutch Prompt-Based Text-to-SQL Systems)

$$LeCo(s_{pred}, s_{gold}) = 1.0 - \frac{d_{lev}(s_{pred}, s_{gold})}{\max(|s_{pred}|, |s_{gold}|)}$$

Structural Correctness (StCo):

Avalia se o grafo de junções e a hierarquia de cláusulas são equivalentes, sendo agnóstica a valores constantes (literals). (Metrics and Benchmarks for Evaluating Dutch Prompt-Based Text-to-SQL Systems)

Skeleton Correctness (SkCo):

Abstrai a consulta para sua forma canônica lógica. Remove-se todo o conteúdo específico do domínio (nomes de tabelas/colunas e valores), comparando apenas a "assinatura" da álgebra relacional empregada. (Metrics and Benchmarks for Evaluating Dutch Prompt-Based Text-to-SQL Systems)

$$SkCo(s_{pred}, s_{gold}) = I(skel(s_{pred}) = skel(s_{gold}))$$

3. Análise das Métricas nas questões consideradas erradas do DATASET

Para avaliar o resultado das métricas no nosso dataset do datasus, foram consideradas como concordantes as métricas que para minha interpretação como “correto” obtiveram resultado superior a “0.5” e que para “incorreto” obtiveram resultados inferiores a “0.5”. Foram desconsiderados os casos no qual o SQL_GROUND_TRUTH foi considerado inadequado ou ambíguo para a pergunta de acordo com minha interpretação pessoal. Para cada uma das métricas, obteve-se um seguinte nível de concordância.

Como foram testadas apenas para os SQL considerados como gerados errados pelo EX, estes testes podem não representar uma avaliação completa.

Métrica	Acurácia	Kappa de Cohen
SOFT EXECUTION F1	83,02%	65,90%
LeCO	67,92%	36,25%
STATISTICAL SUMMARIZATION	67,92%	35,03%
SIMILARITY SCORING	62,26%	27,71%
EX	54,72%	7,82%
CM	50,94%	3,63%
EM	50,94%	0,43%
LFA	50,94%	0%
SkCO	50,94%	0%
StCO	50,94%	0%