

Métricas de Avaliação

Text-to-SQL

Literatura Base da Análise



Sutanto et al. (2025): LLM-Driven Data Generation and a Novel Soft Metric for Evaluating Text-to-SQL in Aviation MRO arXiv preprint arXiv:2506.13785. 1 citação.



Katikeri et al. (2024): EVOLVE: Evaluation of Language-to-SQL Validity and Effectiveness-A Detailed Review Framework for Complex Text-to-SQL Queries. 2024 IEEE International Conference on Big Data (BigData). 3 citações.



Kanburoğlu & Tek (2024): A methodical review of challenges and models. Turkish Journal of Electrical Engineering and Computer Sciences. 44 citações.



Ruben Raaij (2025): Metrics and Benchmarks for Evaluating Dutch Prompt-Based Text-to-SQL Systems, studenttheses.uu.nl. 0 citações.

Tipos de Métricas



Métricas de Execução: Baseada nos dados recuperados: EX, SOFT-F1, etc...



Métricas de Sintaxe: Baseadas na estrutura dos SQL gerados: LFA, LeCO, etc...

Métricas de Execução

(baseadas nos dados recuperados)

Métricas de Execução

EX (Execution Accuracy)

Identidade estrita entre os conjuntos de resultados ($R_{pred} = R_{gold}$). Métrica binária que penaliza qualquer variação na cardinalidade ou conteúdo, mesmo que semanticamente correta em certos contextos.

$$EX(R_{pred}, R_{gold}) = I(R_{pred} \equiv R_{gold})$$

Soft Execution F1

Aborda a avaliação como um problema de Recuperação de Informação. Calcula a média harmônica entre Precision e Recall sobre as tuplas retornadas, permitindo uma gradação de acerto.

$$P = \frac{|T_{pred} \cap T_{gold}|}{|T_{pred}|}, \quad R = \frac{|T_{pred} \cap T_{gold}|}{|T_{gold}|}$$

$$Soft F_1 = \begin{cases} \frac{2 \cdot P \cdot R}{P + R}, & \text{se } P + R > 0 \\ 0, & \text{se } P + R = 0 \end{cases}$$

Métricas de Execução

Valid Efficiency Score (VES)

Mede o custo computacional relativo. Se $EX = 1$, então $VES = \text{Cost}(\text{SQL}_{\text{gold}}) / \text{Cost}(\text{SQL}_{\text{pred}})$. É fundamental para avaliar a viabilidade de consultas em bancos de dados de produção (Big Data). Não avalia corretude.

$$VES(R_{\text{pred}}, R_{\text{gold}}) = I(EX = 1) \cdot \left(\frac{t_{\text{gold}}}{\max(t_{\text{pred}}, \epsilon)} \right)$$

Statistical Summarization

Emprega momentos estatísticos para validar a distribuição dos dados. Compara vetores de propriedades μ , σ^2 de colunas numéricas entre R_{pred} e R_{gold} , sendo resiliente a variações de ordenação que a EX pura penalizaria.

$$\text{Stats} = I(\forall i \in M, |\mu_{\text{pred},i} - \mu_{\text{gold},i}| \leq \theta \wedge |\sigma_{\text{pred},i} - \sigma_{\text{gold},i}| \leq \theta)$$

Métricas de Execução

Similarity Scoring

Calculada através da distância de Jaccard (métrica usada para medir o quão diferentes são os conjuntos) entre os conjuntos de colunas e linhas retornados, quantificando a sobreposição informacional entre os espaços vetoriais dos resultados.

$$J(S_{pred}, S_{gold}) = \frac{|S_{pred} \cap S_{gold}|}{|S_{pred} \cup S_{gold}|}$$



Métricas Sintáticas

(baseadas na estrutura do SQL gerado)

Métricas de Sintaxe

LFA (Logical Form Accuracy)

Equivalência estrita de string. É a métrica mais conservadora, pois ignora a invariância de projeção e a comutatividade de operadores lógicos no SQL.

$$LFA(s_{pred}, s_{gold}) = I(norm(s_{pred}) = norm(s_{gold}))$$

EM (Exact Match Accuracy)

Diferente da LFA, o EM opera sobre subconjuntos. Verifica se os componentes (SELECT **[elemento]** WHERE **[condição]** GROUP BY **[elemento]**) possuem os mesmos elementos, independentemente da ordem textual.

GOLD: SELECT nome, cpf FROM pacientes WHERE idade > 18.

pred: SELECT nome FROM pacientes WHERE idade > 18.

pred: SELECT cpf, nome FROM pacientes WHERE idade > 18.

Métricas de Sintaxe

CM (Component Match)

Decompõe a SQL em módulos. Atribui scores individuais para a precisão de Schema Linking (colunas/tabelas) e Operator Selection (JOINS, agregações).

$$CM(s_{pred}, s_{gold}) = \frac{1}{|K^*|} \sum_{k \in K^*} \frac{|P_k \cap G_k|}{|P_k \cup G_k|}$$

Levenshtein Correctness (LeCo)

Baseia-se na distância de edição $d(s_1, s_2)$ entre as strings. Fornece um gradiente de proximidade textual que auxilia na identificação de erros tipográficos simples em nomes de colunas.

$$LeCo(s_{pred}, s_{gold}) = 1.0 - \frac{d_{lev}(s_{pred}, s_{gold})}{\max(|s_{pred}|, |s_{gold}|)}$$

Métricas de Sintaxe

Structural Correctness (StCo)

Avalia se o grafo de junções e a hierarquia de cláusulas são equivalentes, sendo agnóstica a valores constantes (literais). Ex: **SELECT nome FROM pacientes WHERE idade > [valor]**.

GOLD: SELECT nome FROM pacientes WHERE idade > 25.

pred: SELECT nome FROM pacientes WHERE idade > 18.

pred: SELECT cpf FROM pacientes WHERE idade > 25.

Skeleton Correctness (SkCo)

Abstrai a consulta para sua forma canônica lógica. Remove-se todo o conteúdo específico do domínio e compara apenas a "assinatura" da álgebra relacional empregada. Ex: **SELECT [coluna] FROM [tabela] WHERE [coluna] [operador] [valor]**.

$$SkCo(s_{pred}, s_{gold}) = I(skel(s_{pred}) = skel(s_{gold}))$$

GOLD: SELECT nome FROM pacientes WHERE idade > 18.

pred: SELECT cpf FROM pacientes WHERE idade > 21.

pred: SELECT nome FROM pacientes ORDER BY idade.