

Resultados

Datusus Nosso		
Variante	Qwen2.5-Coder-32B (Vanna)	Qwen3-32B (Vanna)
Base (apenas a biblioteca)	22,56%	24,10%
documentação	23,59%	27,18%
Exemplos	22,56%	25,13%
documentação +Exemplos	20,51%	28,21%
Sih datusus		
Variante	Qwen2.5-Coder-32B (Vanna)	Qwen3-32B (Vanna)
Base (apenas a biblioteca)	22%	23,53%
documentação	57%	58,82%
Exemplos	23,53%	49.02%
documentação +Exemplos	65%	70.59%

Teste das Métricas de Avaliação Text2SQL

Testadas em 4 cenários

1. **C1: Todas as consultas:** Cenário com todas as consultas
2. **C2: Sem questões ambíguas e SQL-Truth incorretos:** Para este caso desconsiderou-se questões ambíguas e SQL-Truth incorretos (impossível as métricas acertarem).
3. **C3: Sem erros de sintaxe:** Para este caso desconsiderou-se a avaliação de consultas com erro de sintaxe. Note que as de métricas de execução serão sempre 0 quando houver erros, mas as métricas sintáticas ainda podem pontuar.
4. **C4: Apenas EX = 0:** Apenas as consultas consideradas erradas pelo EX.

Métricas de Avaliação das Métricas

Para avaliar as métricas foi calculado:


1. A **acurácia** delas no banco de dados em cada um dos cenários.
2. **Kappa de Cohen** tendo como referência a maioria dos avaliadores humanos.

Métricas de Execução

KAPPA	C1	C2	C3	C4
Humano	1.00	1.00	1.00	1.00
EX	0.74	0.79	0.78	0.00
Soft_F1	0.88	0.93	0.92	0.74
Stats	0.81	0.86	0.86	0.48
Similarity	0.80	0.85	0.84	0.48
QAS	0.85	0.88	0.88	0.61

ACURÁCIA	C1	C2	C3	C4
Humano	0.41	0.40	0.69	0.44
EX	0.25	0.26	0.46	0.00
Soft_F1	0.35	0.35	0.61	0.30
Stats	0.29	0.30	0.52	0.13
Similarity	0.35	0.35	0.61	0.34
QAS	0.37	0.37	0.64	0.45

Kappa das Métricas nos Cenários




De acordo com a avaliação humana, 69% das queries sem erro de sintaxe e sem ambiguidade estão corretas.

Métricas de Sintaxe

KAPPA	C1	C2	C3	C4
Humano	1.00	1.00	1.00	1.00
EM	0.32	0.31	0.30	0.06
CM	0.76	0.76	0.79	0.60
LeCo	0.76	0.77	0.82	0.63
SkCo	0.74	0.73	0.72	0.60
PCMF1	0.76	0.76	0.79	0.59

ACURÁCIA	C1	C2	C3	C4
Humano	0.41	0.40	0.69	0.44
EM	0.13	0.10	0.18	0.09
CM	0.50	0.48	0.79	0.74
LeCo	0.49	0.49	0.64	0.56
SkCo	0.39	0.36	0.62	0.55
PCMF1	0.54	0.52	0.84	0.82

Kappa vs Métricas em Cenários



Discussão

1. **A SOFT-F1** é a métrica mais apropriada para replicar a tomada de decisão humana, obtendo 0.92 no Kappa para todas as consultas. Entretanto, a precisão dela diminui para 0.74 quando $EX=0$, que é o caso onde realmente precisamos de uma outra métrica para avaliar a corretude.
2. **A LeCO** é a métrica sintática que melhor pontuou.
3. Mesmo usando essas métricas, a acurácia do projeto tem um máximo de 41% considerando erros de sintaxe e de *ground truth* e 69% sem erros. De acordo com a métrica SOFT-F1 a acurácia é de 61% sem erros e com a LeCO de 64%.
4. É possível combinar dois tipos de métricas (sintática e execução) para avaliar a corretude. A métrica QAS implementa isso internamente.