

Reunião 06/02

Nosso Benchmark DATASUS

- 201 Queries
 - 15 excluídas pelo tempo de execução (8h+)
- Das 186 restantes são divididas por dificuldades:
 - simple - 58
 - medium - 109
 - hard - 40

Bibliotecas, Modelos e Métrica

- Bibliotecas: PremSql e VannaAI
- Modelos:
 - Llama-3.1-8B-Instruct
 - Qwen2.5-Coder-32B-Instruct
- Métrica:
 - Execution Accuracy (EX) : resultado da query gerada pelo modelo é igual ao resultado da query correta

Resultados

	PremSql	VannaAi
Llama3.1-8B	2.61%	2.30%
Qwen2.5-Coder	4.30%	4.30%

- Motivo dos erros:
 - Algumas consultas geradas estão corretas mas não retornam as mesmas colunas do sql
 - Sql gerado pelo modelo mal otimizado demoram mais de 10x o tempo da consulta original
 - LLM usando tabelas/colunas q não existem

Resultados

- Ex:
 - Pergunta: Liste os hospitais que possuem latitude ou longitude ausente no endereço.
 - SQL correto retorna as colunas: nome_instituicao, codigo_cnes, cnpj_instituicao, endereco_id, latitude, longitude
 - SQL gerado: id_instituicao, nome_instituicao, latitude, longitude

Reunião 20/02

Nosso Benchmark DATASUS

- 186 Queries são divididas por dificuldades:
 - simple - 58
 - medium - 109
 - hard - 40

Bibliotecas, Modelos e Métrica

- Bibliotecas: PremSql e VannaAI
- Modelos:
 - Llama-3.1-8B-Instruct
 - Qwen2.5-Coder-32B-Instruct
- Métrica:
 - Execution Accuracy (EX) : resultado da query gerada pelo modelo é igual ao resultado da query correta

Resultados

	EX		SQL gerado não executou por alucinação		SQL gerado time out	
	PremSql	VannaAi	PremSql	VannaAi	PremSql	VannaAi
Llama3.1-8 B	2.61%	3.2%	20%	17%	7%	5%
Qwen2.5-C oder	4.30%	4.8%	31%	5%	6%	6%

Avaliação manual dos SQLs

- Avaliamos manualmente 18 dos Sqls gerados e que executaram mas não estão iguais ao SQL correto.
 - 10% da base
 - 2 avaliadores por consulta

	Total Acertos	Total Erros	Total Não concordância	cohen kappa
VannaAi Llama	6	9	3	6.582
Premsql Llama	6	9	3	6.667
VannaAi Qwen	7	8	3	6.469
Premsql Qwen	7	7	4	5.47

Avaliação manual dos SQLs

- Consultas corretas: O LLM responde a questão colunas diferentes das do SQL original
- Erros:
 - Alucinação: LLM gera consultas que não respondem a pergunta
 - “Para cada município, qual o número total de leitos SUS considerando o **registro mais recente de cada instituição?**”
 - Falta de informação:
 - “Liste todas as compras cuja modalidade contenha 'Pregão', incluindo o nome do fornecedor e do fabricante.” No banco, Pregão é escrito em maiúsculo
 - Pergunta ambígua:
 - “Liste os hospitais cujo endereço apresenta latitude ou longitude faltante.”


Avaliação manual dos SQLs

- Erros:
 - Sqls retornando tabelas vazias:
 - “Quantas compras foram realizadas por cada modalidade_de_compra no ano corrente?”
 - Banco não tem informações sobre o ano atual
 - “Quais produtos são genéricos e estão atualmente estocados em alguma instituição?”
 - Um dos Bancos não tem informações sobre se o produto é generico

VannaAI e PrenSQL no Bird

	EX - Bird
Prem-1B-SQL Finetuned	51,54%
vannaai + Gpt-4	61,28%
Vanna-72B Finetuned	67,80%

CDF tempo de execução



Reunião 27/02

Benchmarks

Datusus (Nosso) - 60 Consultas:

- simple - 33
- medium - 18
- hard - 9

Datusus (SIH) - 56 Consultas:

- simple - 17
- medium - 19
- hard - 15

Bibliotecas, Modelos e Métrica

- Bibliotecas: PremSql e VannaAI
- Modelos:
 - Qwen2.5-Coder-32B-Instruct
 - Llama-3.1-8B-Instruct
 - Llama-3-sqlcoder-8B
 - prem-1B-SQL
- Métrica:
 - Execution Accuracy (EX) : Compara o resultado da query gerada pelo modelo com o resultado da query correta

Resultados

Model	Sih Datasus		Datasus Nosso	
	PremSQL	vannaAi	PremSQL	vannaAi
Qwen2.5-Coder-32B-Instruct	31%	22%	17%	23%
Llama-3.1-8B-Instruct	0%	16%	2%	13%
llama-3-sqlcoder-8b	33%	20%	23%	10%
prem-1B-SQL	24%	20%	10%	7%

Resultados

Difficulty	Sih Datasus	Datasus Nosso
simple	76%	42%
medium	0%	0%
hard	26%	0%

- Model: llama-3-sqlcoder-8b com PremSQL

Sih DATASUS

- No artigo do SIH Datasus é obtido um EX de 82.9%




Figure 2. Agent workflow: LLM-driven tasks (gray), database operations (blue), and validation (green).

Reunião 06/03

Benchmarks

Datusus (Nosso) - 60 Consultas:

- simple - 33
- medium - 18
- hard - 9

Datusus (SIH) - 51 Consultas:

- simple - 17
- medium - 19
- hard - 15

Bibliotecas, Modelos e Métrica

- Bibliotecas: PremSql e VannaAI
- Modelos:
 - Qwen2.5-Coder-32B-Instruct
 - Llama-3.1-8B-Instruct
 - Llama-3-sqlcoder-8B
 - prem-1B-SQL
- Métrica:
 - Execution Accuracy (EX) : Compara o resultado da query gerada pelo modelo com o resultado da query correta

Resultados - Última reunião

Model	Sih Datasus		Datasus Nosso	
	PremSQL	vannaAi	PremSQL	vannaAi
Qwen2.5-Coder-32B-Instruct	31%	22%	17%	23%
Llama-3.1-8B-Instruct	0%	16%	2%	13%
llama-3-sqlcoder-8b	33%	20%	23%	10%
prem-1B-SQL	24%	20%	10%	7%

Resultados - Vanna com contexto

Model	Sih Datasus			Datasus Nosso		
	PremSQL	vannaAi	vannaAi + contexto	PremSQL	vannaAi	vannaAi + contexto
Qwen2.5-Coder-32B-Instruct	31%	22%	57%	17%	23%	25%
Llama-3.1-8B-Instruct	0%	16%	14%	2%	13%	17%
llama-3-sqlcoder-8b	33%	20%	22%	23%	10%	12%
prem-1B-SQL	24%	20%	22%	10%	7%	7%

- Contexto é uma documentação do banco de dados

3. `procedimentos` (Estatísticas de Procedimentos)

Tabela primária para contagem de intervenções médicas.

* **Colunas Chave:** `PROC\_REA` (Código), `NOME\_PROC` (Descrição).

Resultados - Reprodução código da PUC

Sih Datasus		
Difficulty	Reprodução - PUC - Llama 3	vannaAi + contexto + Qwen 2.5 - 32B
simple	94.1%	94.1%
medium	88.2%	42.1%
hard	57.1%	33.3%
Total	81.2%	57%

Reunião 13/03

Benchmarks

Datusus (Nosso) - 60 Consultas:

- simple - 33
- medium - 18
- hard - 9

Datusus (SIH) - Grupo de pesquisa da PUC RS- 51 Consultas:

- simple - 17
- medium - 19
- hard - 15

Bibliotecas, Modelos e Métrica

- Bibliotecas: PremSql e VannaAI
- Métrica:
 - Execution Accuracy (EX) : Compara o resultado da query gerada pelo modelo com o resultado da query correta

Bibliotecas, Modelos e Métrica

- Modelos:
 - 11 Modelos que tiveram os melhores resultados nos artigos de text2sql em PT e 3 Modelos treinados especificamente para text2sql.
 - 10 Open source e 4 Proprietarios
 - Executados:
 - Qwen2.5-Coder-32B-Instruct
 - Qwen2.5-Coder-14B-Instruct
 - Qwen2.5-Coder-7B-Instruct
 - Llama-3.1-8B-Instruct
 - llama-3-sqlcoder-8b

Resultados

Model	Sih Datasus			Datasus Nosso		
	PremSQL	vannaAi	vannaAi + Documentação	PremSQL	vannaAi	vannaAi + Documentação
Qwen2.5-Coder-32B-Instruct	31%	22%	57%	17%	23%	25%
Qwen2.5-Coder-14B-Instruct	31%	20%	35%	27%	27%	20%
Qwen2.5-Coder-7B-Instruct	24%	16%	24%	3%	12%	17%
Llama-3.1-8B-Instruct	0%	16%	14%	2%	13%	17%
llama-3-sqlcoder-8b	33%	20%	22%	23%	10%	12%

Resultados - Reprodução código da PUC

Sih Datasus		
Difficulty	Reprodução - PUC - Llama 3	vannaAi + contexto + Qwen 2.5 - 32B
simple	94.1%	94.1%
medium	88.2%	42.1%
hard	57.1%	33.3%
Total	81.2%	57%

Sih DATASUS

- No artigo do SIH Datasus é obtido um EX de 82.9%






Figure 2. Agent workflow: LLM-driven tasks (gray), database operations (blue), and validation (green).

PremSql



VannaAi



Próximos passos

- Executando o restante dos modelos Open source encontrados.
- Investigando formas de dar mais contexto das bases de dados aos modelos.

Reunião 10/04


Benchmarks

- 4 Benchmarks em Portugues + 1 Proposto

Base de Dados	Contexto	# Pares NL-SQL	# BDs	# Méd. tab.	# Méd. pal.
Spider-pt (dev)	Tradução do fold dev do Spider 1.0	1034	20	4 $\pm$ 2.5	14.04 $\pm$ 4.93
Spider-pt (test)	Tradução do fold test do Spider 1.0	2147	40	4.5 $\pm$ 2.88	14.41 $\pm$ 4.91
text2SQL4PM	Registros de pagamentos e requerimentos	1655	1	6	15.84 $\pm$ 6.98
DATASUS (SIH/SUS)	Dados de hospitalizações	51	1	15	16.25 $\pm$ 13.75
DATASUS (Nossa)	Dados de compra, armazenamento de farmacos e de instituições hospitalares	195	1	15	52.34 $\pm$ 40.13

Benchmarks

- Dificuldade baseada na do Benchmarks Spider



Modelos e Metricas

- Modelos abertos destacados no Top 3 dos artigos de benchmark.
 - Qwen2.5-Coder-32B-Instruct
 - Qwen2.5-Coder-14B-Instruct
 - Qwen2.5-Coder-7B-Instruct
 - Qwen2.5-32B-Instruct
 - Llama-3.1-8B-Instruct
 - llama-3-sqlcoder-8b
- Usando apenas o modelo zero-shot
- Metricas:
 - EX = Acuracia de execu  o
 - CM = correspond  ncia de componentes

Prompt zero-shot utilizado

Exemplo de prompt

[System]:

You are an expert SQL assistant. Given the database schema below, write a single valid SQL query that answers the user's question. Return ONLY the SQL query, without explanations or markdown.

Schema

```
CREATE TABLE admissions (id INTEGER, hospital_id INTEGER, patient_age INTEGER, diagnosis_code VARCHAR, ...);  
CREATE TABLE hospital (id INTEGER, name VARCHAR, city VARCHAR, ...);
```


[User]:

Quantas internações ocorreram em Porto Alegre em 2020?


Resultados - Raw Model

modelo	DATASUS (SIH/SUS)		spider (test)		spider (dev)		text2SQL4PM		DATASUS (Nossa)	
	CM	EX	CM	EX	CM	EX	CM	EX	CM	EX
Qwen2.5-Coder-32B	57.6%	23.5%	57.1%	70.7%	59.7%	65.6%	70.6%	54.4%	43.1%	9.2%
Qwen2.5-Coder-14B	58.7%	27.5%	56.3%	69.7%	57.4%	65.3%	69.7%	54.1%	44.3%	8.9%
Qwen2.5-Coder-7B	56.7%	23.5%	55.5%	65.2%	57.8%	59.9%	66.5%	47.6%	35.4%	7.7%
Qwen2.5-32B	51.1%	19.6%	58.0%	68.2%	58.1%	63.4%	72.5%	54.1%	-	-
Llama-3.1-8B	50.7%	13.7%	54.5%	59.7%	55.2%	56.5%	66.0%	53.5%	-	-
Llama-3-sqlcoder-8b	50.3%	17.6%	42.8%	42.5%	43.5%	40.8%	59.4%	35.5%	-	-

PremSql



VannaAi



Resultados com bibliotecas

modelo	DATASUS (SIH/SUS) - EX			
	Raw Model	PremSQL	vannaAi	vannaAi + contexto
Qwen2.5-Coder-32B	23.5%	31%	22%	57%
Qwen2.5-Coder-14B	27.5%	31%	20%	35%
Qwen2.5-Coder-7B	23.5%	24%	16%	24%
modelo	DATASUS (Nossa) - EX			
	Raw Model	PremSQL	vannaAi	vannaAi + contexto
Qwen2.5-Coder-32B	9.2%	-	22.6%	23.6%
Qwen2.5-Coder-14B	8.9%	-	21.3%	20%
Qwen2.5-Coder-7B	7.7%	-	13.8%	16.4%

Resultados por dificuldade

Qwen2.5-Coder-32B-Instruct						
modelo	Total	Fácil	Média	Difícil	Extra-Difícil	Não Avaliada
Nossa (RawModel)	9.2%	20.0%	0.0%	0.0%	-	-
Nossa (vannaAi)	22.6%	44.4%	1.8%	6.2%	-	-
Nossa (vannaAi + contexto)	23.6%	47.8%	0.0%	6.2%	-	-
DATASUS (SIH/SUS)	23.5%	58.8%	10.5%	0.0%	-	-
spider (test)	70.7%	89.4%	74.5%	67.9%	50.3%	-
spider (dev)	65.6%	86.5%	69.2%	64.2%	39.2%	-
text2SQL4PM	54.4%	78.3%	53.2%	49.4%	53.6%	39.2%

Reunião 29/04

Resultados Passando Contexto e Exemplos

modelo	Qwen2.5-Coder-32B - EX					
	Raw Model	PremSQL	vannaAi	vannaAi + documentação	vannaAi + exemplo	vannaAi + exemplo + documentação
DATASUS (SIH/SUS)	23.5%	31%	22%	57%	23.5%	65%
DATASUS (Nossa)	9.2%	17%	22.6%	23.6%	22.5%	20.5%

Análise Dos Erros

- Erros do modelo Qwen2.5-Coder-32B-Instruct com a biblioteca vannaAi + documentação

ERRO	(149 erros de 195)
RESULTADO_INCORRETO	67 (45.0%)
ERRO_SINTAXE	54 (36.2%)
DIALETO_INCOMPATIVEL	17 (11.4%)
COLUNA_INEXISTENTE	7 (4.7%)
OUTPUT_INCOMPLETO	3 (2.0%)
TABELA_INEXISTENTE	1 (0.7%)

Análise Qualitativa Dos Erros

- Avaliação manual das consultas que executaram mas apresentaram um resultado incorreto;
 - Avaliamos 20 Consultas
 - 3 Avaliadores para cada consulta
 - Fleiss' Kappa = 0,259
- Categorização dos erros em 3 conjuntos:
 - SQL gerado responde a pergunta;
 - SQL gerado errado;
 - Pergunta com ambiguidade;

Análise Qualitativa Dos Erros

- SQL gerado responde a pergunta;
 - 7 casos (Pelo menos 2 avaliadores concordaram);
 - Ex: “Entre janeiro de 2023 e dezembro de 2024, me mostre os 10 fornecedores que venderam a maior variedade de produtos para a mantenedora; para cada um, inclua o código do fornecedor, o nome, quantos tipos diferentes de produtos ele vendeu nesse período e a mediana do preço cobrado por unidade.”
 - 2 SQLs são iguais mas um faz o arredondamento da mediana do preço

Análise Qualitativa Dos Erros

- SQL gerado errado;
 - 9 casos (Pelo menos 2 avaliadores concordaram);
 - ID 15 — GROUP BY m.municipio (nome) em vez de municipio_id. Nomes de municípios podem se repetir entre UFs, fundindo registros errados.
 - ID 121 — Falta filtro instituicao_id IS NOT NULL. IDs nulos entram no ranking.
 - ID 187 — JOIN i.endereco_id = m.codigo_do_municipio mistura campos de naturezas diferentes (endereco_id é FK para endereco, não para municipio). Retorna vazio.

Análise Qualitativa Dos Erros

- Pergunta com ambiguidade;
 - 4 casos (Pelo menos 2 avaliadores concordaram);
 - ID 19 — "biênio entre 31/12/2022 e 31/12/2024"
 - ID 105 — "período de dois anos encerrado em 31/12/2024"
 - ID 106 — "biênio encerrado em 31/12/2024"
 - ID 107 — "biênio entre 31/12/2022 e 31/12/2024"
 - modelo gera BETWEEN '2022-12-31' AND '2024-12-31', gold usa `>= ('2024-12-31'::date - INTERVAL '2 years')`

Análise Qualitativa Dos Erros

- Um dos avaliadores identificou uma pergunta que não faz muito sentido:
 - "Mostre a contagem de registros da tabela CATMAT agrupada pelo comprimento de descricao_catmat nas categorias: curta (<20 caracteres), média (20–79 caracteres) e longa (>=80 caracteres), ordenada pela contagem em ordem decrescente."
 - Catman é só um código pra identificar os medicamentos

Reunião 22/05

XiYanSQL

- Fine tuning do Qwen 2.5 - coder para tarefa de text-to-sql.
 - Uso do M-Schema - Esquema do banco de dados mais informativo que o DDL
 - Prompt disponível em Chinês e Inglês
- Método XiYan-SQL




Fig. 1. Overview of the proposed XiYan-SQL framework, including three steps: Schema Filter, Multiple SQL Generation, and SQL Selection.

M-schema

DDL Schema	MAC-SQL Schema	M-Schema
<pre>CREATE TABLE hero_power (hero_id INTEGER, power_id INTEGER, FOREIGN KEY (power_id) REFERENCES superpower(id)); CREATE TABLE superpower (id INTEGER PRIMARY KEY, power_name TEXT);</pre>	<pre>{DB_ID} superhero {Schema} # Table: hero_power [(hero_id, hero id.), (power_id, power id.)] # Table: superpower [(id, id.), (power_name, power name, Value examples: ['Agility'].)] {Foreign keys} hero_power.hero_id = superpower.id</pre>	<pre>{DB_ID} superhero {Schema} # Table: hero_power [(hero_id:INTEGER, Primary Key, the id of the hero Maps to superhero(id), Examples: [1, 2, 3]), (power_id:INTEGER, the id of the power Maps to superpower(id), Examples: [1, 18, 26])] # Table: superpower [(id:INTEGER, Primary Key, the unique identifier of the superpower, Examples: [1, 2, 3]), (power_name:TEXT, the superpower name, Examples: [Agility, Accelerated Healing, Lantern Power Ring])] {Foreign keys} hero_power.power_id=superpower.id</pre>

Figure 2: Examples of representing a database schema in DDL Schema, MAC-SQL Schema and M-Schema. The red text highlights the differences between M-Schema and MAC-SQL Schema. M-Schema adds data types, primary key markings, and changes the rules for displaying sample values.

Resultados XiYanSQL

modelo	Qwen2.5-Coder-32B - EX					
	Raw Model	PremSQL	vannaAi	vannaAi + documentação	vannaAi + exemplo	vannaAi + exemplo + documentação
DATASUS (SIH/SUS)	23.5%	31%	22%	57%	23.5%	65%
DATASUS (Nossa)	9.2%	17%	22.6%	23.6%	22.5%	20.5%

	XiYanSQL - 7B		XiYanSQL - 32B		XiYanSQL - 32B + documentação
	CN	EN	CN	EN	CN
DATASUS (SIH/SUS)	27,45%	23,53%	33,33%	33,33%	45,10%
DATASUS (Nossa)	19,49%	17,44%	20,00%	17,44%	20,00%

Análise Dos Erros

- Erros do modelo Qwen2.5-Coder-32B-Instruct com a biblioteca vannaAi + documentação

ERRO	(149 erros de 195)
RESULTADO_INCORRETO	67 (45.0%)
ERRO_SINTAXE	54 (36.2%)
DIALETO_INCOMPATIVEL	17 (11.4%)
COLUNA_INEXISTENTE	7 (4.7%)
OUTPUT_INCOMPLETO	3 (2.0%)
TABELA_INEXISTENTE	1 (0.7%)

Análise Qualitativa Dos Erros

- Avaliação manual das consultas que executaram mas apresentaram um resultado incorreto;
 - Avaliamos 67 Consultas
 - 3 Avaliadores para cada consulta
 - Fleiss' Kappa = 0,5 (moderada)
- Categorização dos erros em 3 conjuntos:
 - SQL gerado responde a pergunta;
 - SQL gerado errado;
 - Pergunta com ambiguidade ou Sql gerado é melhor que o original;

Análise Qualitativa Dos Erros

- SQL gerado responde a pergunta;
 - 31 casos (Pelo menos 2 avaliadores concordaram);
 - Ex: “Entre janeiro de 2023 e dezembro de 2024, me mostre os 10 fornecedores que venderam a maior variedade de produtos para a mantenedora; para cada um, inclua o código do fornecedor, o nome, quantos tipos diferentes de produtos ele vendeu nesse período e a mediana do preço cobrado por unidade.”
 - 2 SQLs são iguais mas um faz o arredondamento da mediana do preço

Análise Qualitativa Dos Erros

- SQL gerado errado;
 - 36 casos (Pelo menos 2 avaliadores concordaram);
 - ID 15 — GROUP BY m.municipio (nome) em vez de municipio_id. Nomes de municípios podem se repetir entre UFs, fundindo registros errados.
 - ID 121 — Falta filtro instituicao_id IS NOT NULL. IDs nulos entram no ranking.
 - ID 187 — JOIN i.endereco_id = m.codigo_do_municipio mistura campos de naturezas diferentes (endereco_id é FK para endereco, não para municipio). Retorna vazio.

Análise Qualitativa Dos Erros

- Pergunta com ambiguidade ou Sql gerado é melhor que o original;
 - 14 casos:
 - ID 19 — "biênio entre 31/12/2022 e 31/12/2024"
 - ID 14 — "Liste as 100 categorias de material (código catmat)"
 - GT não retorna o código catmat

Reunião 29/05

Resultados

Variante	Qwen2.5-Coder-32B (Vanna)	Qwen3-32B (Vanna)
Base (apenas a biblioteca)	22,56%	24,10%
documentação	23,59%	27,18%
Exemplos	22,56%	25,13%
documentação +Exemplos	20,51%	28,21%
Variante	Qwen2.5-Coder-32B (Vanna)	Qwen3-32B (Vanna)
Base (apenas a biblioteca)	22%	23,53%
documentação	57%	58,82%
Exemplos	23,53%	49.02%
documentação +Exemplos	65%	70.59%

Reunião 24/06

Resultados


Datusus Nosso		
Variante	Qwen2.5-Coder-32B (Vanna)	Qwen3-32B (Vanna)
Base (apenas a biblioteca)	22,56%	24,10%
documentação	23,59%	27,18%
Exemplos	22,56%	25,13%
documentação +Exemplos	20,51%	28,21%
Sih datusus		
Variante	Qwen2.5-Coder-32B (Vanna)	Qwen3-32B (Vanna)
Base (apenas a biblioteca)	22%	23,53%
documentação	57%	58,82%
Exemplos	23,53%	49.02%
documentação +Exemplos	65%	70.59%

Métricas de Execução

KAPPA	TODAS	sql truth correto	sem erro sintaxe	só EX=0
Humano	1.00	1.00	1.00	1.00
EX	0.74	0.79	0.78	0.00
Soft_F1	0.88	0.93	0.92	0.74
Stats	0.81	0.86	0.86	0.48
Similarity	0.80	0.85	0.84	0.48
QAS	0.85	0.88	0.88	0.61

ACURÁCIA	TODAS	sql truth correto	sem erro sintaxe	só EX=0
Humano	0.41	0.40	0.69	0.44
EX	0.25	0.26	0.46	0.00
Soft_F1	0.35	0.35	0.61	0.30
Stats	0.29	0.30	0.52	0.13
Similarity	0.35	0.35	0.61	0.34
QAS	0.37	0.37	0.64	0.45

Kappa das Métricas nos Cenários




De acordo com a avaliação humana, 69% das queries sem erro de sintaxe e sem ambiguidade estão corretas.

Métricas de Sintaxe

KAPPA	TODAS	sql truth correto	sem erro sintaxe	só EX=0
Humano	1.00	1.00	1.00	1.00
EM	0.32	0.31	0.30	0.06
CM	0.76	0.76	0.79	0.60
LeCo	0.76	0.77	0.82	0.63
SkCo	0.74	0.73	0.72	0.60
PCMF1	0.76	0.76	0.79	0.59

ACURÁCIA	TODAS	sql truth correto	sem erro sintaxe	só EX=0
Humano	0.41	0.40	0.69	0.44
EM	0.13	0.10	0.18	0.09
CM	0.50	0.48	0.79	0.74
LeCo	0.49	0.49	0.64	0.56
SkCo	0.39	0.36	0.62	0.55
PCMF1	0.54	0.52	0.84	0.82

Kappa vs Métricas em Cenários



Discussão

1. **A SOFT-F1** é a métrica mais apropriada para replicar a tomada de decisão humana, obtendo 0.92 no Kappa para todas as consultas. Entretanto, a precisão dela diminui para 0.74 quando $EX=0$, que é o caso onde realmente precisamos de uma outra métrica para avaliar a corretude.
2. **A LeCO** é a métrica sintática que melhor pontuou.
3. Mesmo usando essas métricas, a acurácia do projeto tem um máximo de 41% considerando erros de sintaxe e *ground truth* e 69% sem erros. De acordo com a métrica SOFT-F1 a acurácia é de 61% sem erros e com a LeCO de 64%.
4. É possível combinar dois tipos de métricas (sintática e execução) para avaliar a corretude. A métrica QAS implementa isso internamente.