

Avaliação Sistemática de Text-to-SQL em Português

Um Benchmark Unificado Multi-Domínio

Guilherme Fonseca, Julio C. S. Reis, Matheus Botelho
Pedro Calais, Emerson A. Simoes, Lucas R. Silva
Eduardo Camara, Jaide Zardin, Rodrigo Gonçalves
Gustavo Ribeiro, Yago Lobato, Allan Sene
Altigran S. Silva e Marcos A. Gonçalves

SBBD 2026 • São Carlos, SP



01 - Contexto & Motivação

Text-to-SQL

Converte perguntas em linguagem natural em consultas SQL executáveis.

Avaliação concentrada em inglês

A avaliação permanece fortemente concentrada no idioma inglês e em benchmarks isolados, como Spider e BIRD.

Português: ecossistema fragmentado

Trabalhos existentes concentram-se em bases específicas ou domínios isolados, dificultando comparações consistentes.

Risco de estimativas otimistas

Benchmarks isolados podem não refletir a diversidade e a complexidade de cenários reais.

Objetivo

Avaliação sistemática e unificada da tarefa Text-to-SQL em português, consolidando múltiplas bases e comparando diferentes LLMs sob um protocolo experimental padronizado.

QP1: quais bases estão disponíveis e quais suas características estruturais e semânticas?

QP2: qual é a efetividade dos LLMs em diferentes cenários e níveis de complexidade?

02 - Lacuna: comparabilidade × realismo

Benchmarks traduzidos

Favorecem comparabilidade

- Adaptações do Spider para o português
- Preservam a estrutura do benchmark original
- Herdam baixa representatividade de cenários reais
- Protocolos experimentais variam entre estudos

“favorecem comparabilidade mas carecem de realismo”

Bases de domínio específico

Aumentam representatividade

- DATASUS, Funarte, Censo Educacional e INEP
- Cenários mais próximos de aplicações reais
- Tipicamente restritas a domínios específicos
- Avaliadas de forma isolada, sem integração

“aumentam a representatividade mas comprometem a comparabilidade”

A ausência de uma avaliação integrada que concilie esses aspectos limita a compreensão do desempenho real dos modelos.

03 - Proposta e contribuições

C1

Benchmark unificado

Quatro bases públicas — Spider-pt (dev e test), text2SQL4PM e DATASUS (SIH/SUS) — cobrindo diferentes domínios, estruturas e níveis de dificuldade.

C2

Avaliação sistemática de seis LLMs abertos

Comparação com métricas complementares (EX e CM) sob um protocolo reprodutível e controlado.

E

Escopo integrado da avaliação

Múltiplos domínios reais e sintéticos, protocolo homogêneo entre bases e avaliação comparativa cross-domain sob condições controladas.

Até onde temos conhecimento, é o primeiro trabalho a avaliar múltiplas bases de Text-to-SQL em português sob um protocolo unificado.

04 - QP1: bases consolidadas no benchmark

Base de Dados	Contexto	# Pares NL-SQL	# BDs	# Méd. tab.	# Méd. pal.
Spider-pt (dev)	Tradução do fold dev do Spider 1.0	1034	20	4,00 $\pm$ 2,50	14,04 $\pm$ 4,93
Spider-pt (test)	Tradução do fold test do Spider 1.0	2147	40	4,50 $\pm$ 2,88	14,41 $\pm$ 4,91
text2SQL4PM	Registros de pagamentos e requerimentos	1655	1	6,00 $\pm$ 0,0	15,84 $\pm$ 6,98
DATASUS (SIH/SUS)	Dados de hospitalizações	51	1	15,00 $\pm$ 0,00	16,25 $\pm$ 13,75

Tabela 1. Bases de dados de Text-to-SQL português.

Spider-pt

Versões traduzidas de um benchmark amplamente utilizado.

text2SQL4PM e DATASUS

Refletem cenários mais próximos de aplicações reais, com maior especificidade de domínio.

DATASUS

É o único conjunto de dados inteiramente em português.

04 - QP1: níveis de dificuldade




Figura 1. Distribuição dos níveis de dificuldade por base de dados.

Como a dificuldade é definida

- Quatro níveis: fácil, média, difícil e extra-difícil
- Classificação baseada na complexidade estrutural das queries, incluindo operações, junções e subconsultas
- text2SQL4PM inclui ainda a classe “Não classificada”
- As bases apresentam variações relevantes na distribuição de dificuldade

A heterogeneidade entre bases reforça a necessidade de uma avaliação unificada.

05 - Setup experimental

Modelos

Qwen2.5

- Coder-7B-Instruct
- Coder-14B-Instruct
- Coder-32B-Instruct
- 32B-Instruct

Llama

- Llama-3.1-8B-Instruct
- llama-3-sqlcoder-8b

Total

6 LLMs de código aberto

Geração

Prompting

Zero-shot: esquema do banco + pergunta do usuário, sem exemplos.

Idioma

Prompt em inglês; perguntas em português.

Decodificação

Greedy decoding, com saída determinística.

Execução e avaliação

Quantização

4 bits (NF4) em bfloat16 via BitsAndBytes.

Métricas

Execution Accuracy (EX)
Component Matching (CM)

05 - Estratégia de prompting zero-shot

Exemplo de *prompt*

[System] :

You are an expert SQL assistant. Given the database schema below, write a single valid SQL query that answers the user's question. Return ONLY the SQL query, without explanations or markdown.

Schema

```
CREATE TABLE admissions (id INTEGER, hospital_id INTEGER, patient_age INTEGER,
diagnosis_code VARCHAR, ...);
CREATE TABLE hospital (id INTEGER, name VARCHAR, city VARCHAR, ...);
```

[User] :

Quantas internações ocorreram em Porto Alegre em 2020?

Figura 2. Exemplo de prompt utilizado na abordagem zero-shot.

Para todos os modelos, o prompt contém apenas o esquema do banco de dados e a pergunta do usuário, sem exemplos de pares pergunta-SQL.

Na execução real, o esquema completo de todas as tabelas é enviado no prompt.

05 · Métricas de avaliação

Acurácia de Execução (EX)

Compara o resultado da execução da consulta SQL gerada pelo modelo com o resultado da consulta de referência (gold).

Uma predição é correta se ambas as execuções retornam o mesmo conjunto de resultados.

É robusta a variações sintáticas válidas, pois consultas SQL diferentes podem produzir o mesmo resultado.

Component Matching (CM)

Avalia a correspondência entre componentes individuais da consulta gerada e da consulta de referência.

Considera cláusulas como SELECT, WHERE, GROUP BY e ORDER BY, entre outras.

De forma geral, valores mais altos para ambas as métricas indicam melhor desempenho dos modelos.

EX e CM são métricas complementares adotadas para a avaliação comparativa.

06 · QP2: resultados agregados — DATASUS e Spider (test)

modelo	CM	EX	EX				
	Total	Total	Fácil	Média	Difícil	Extra-Difícil	Não Avaliada
DATASUS (SIH/SUS)							
Qwen2.5-Coder-32B-Instruct	57.6%	23.5%	58.8%	10.5%	0.0%	-	-
Qwen2.5-Coder-14B-Instruct	58.7%	27.5%	64.7%	10.5%	6.7%	-	-
Qwen2.5-Coder-7B-Instruct	56.7%	23.5%	64.7%	5.3%	0.0%	-	-
Qwen2.5-32B-Instruct	51.1%	19.6%	47.1%	10.5%	0.0%	-	-
Llama-3.1-8B-Instruct	50.7%	13.7%	35.3%	5.3%	0.0%	-	-
llama-3-sqlcoder-8b	50.3%	17.6%	52.9%	0.0%	0.0%	-	-
spider (test)							
Qwen2.5-Coder-32B-Instruct	57.1%	70.7%	89.4%	74.5%	67.9%	50.3%	-
Qwen2.5-Coder-14B-Instruct	56.3%	69.7%	91.3%	73.3%	65.9%	48.1%	-
Qwen2.5-Coder-7B-Instruct	55.5%	65.2%	87.5%	70.0%	63.5%	39.1%	-
Qwen2.5-32B-Instruct	58.0%	68.2%	87.1%	71.2%	69.1%	46.0%	-
Llama-3.1-8B-Instruct	54.5%	59.7%	81.4%	64.1%	57.3%	35.7%	-
llama-3-sqlcoder-8b	42.8%	42.5%	69.6%	43.7%	38.8%	20.3%	-

Spider (test): melhor EX = 70,7% • DATASUS: melhor EX = 27,5%

06 · QP2: resultados agregados — Spider (dev) e text2SQL4PM

spider (dev)							
Qwen2.5-Coder-32B-Instruct	59.7%	65.6%	86.5%	69.2%	64.2%	39.2%	-
Qwen2.5-Coder-14B-Instruct	57.4%	65.3%	86.0%	69.5%	62.3%	39.2%	-
Qwen2.5-Coder-7B-Instruct	57.8%	59.9%	86.0%	62.9%	60.4%	28.2%	-
Qwen2.5-32B-Instruct	58.1%	63.4%	87.8%	67.6%	59.1%	34.8%	-
Llama-3.1-8B-Instruct	55.2%	56.5%	82.0%	58.9%	56.0%	27.3%	-
llama-3-sqlcoder-8b	43.5%	40.8%	71.6%	42.0%	32.7%	14.1%	-
text2SQL4PM							
Qwen2.5-Coder-32B-Instruct	70.6%	54.4%	78.3%	53.2%	49.4%	53.6%	39.2%
Qwen2.5-Coder-14B-Instruct	69.7%	54.1%	77.6%	52.3%	55.4%	53.6%	35.9%
Qwen2.5-Coder-7B-Instruct	66.5%	47.6%	66.8%	44.8%	52.6%	52.6%	30.4%
Qwen2.5-32B-Instruct	72.5%	54.1%	77.6%	52.9%	61.4%	53.6%	30.4%
Llama-3.1-8B-Instruct	66.0%	53.5%	69.9%	50.0%	70.1%	64.9%	30.4%
llama-3-sqlcoder-8b	59.4%	35.5%	48.1%	35.2%	37.5%	28.9%	25.2%

De forma geral, a família Qwen2.5 alcança os maiores valores de CM e EX nas bases avaliadas.

06 - QP2: comportamento dos modelos

3/4

Qwen2.5-Coder-32B lidera em EX em 3 das 4 bases.

Especialização

Coder-32B supera Qwen2.5-32B em EX no Spider test/dev e DATASUS.

Escala

No DATASUS, Coder-14B supera Coder-32B em EX: 27,5% vs. 23,5%.

Especialização em código

A especialização gera ganhos consistentes na família Qwen2.5. Porém, o SQLCoder-8B não supera o Llama-3.1-8B, sugerindo que os ganhos dependem da qualidade do modelo base.

Escala

Há uma tendência geral de melhoria com o aumento do número de parâmetros. A principal exceção é o DATASUS, em que o modelo de 14B supera o de 32B.

Modelos menores podem apresentar melhor adaptação em cenários específicos e mais desafiadores.

06 · QP2: gap entre benchmark tradicional e cenário real

70,7%

Melhor EX no Spider (test)

Benchmark tradicional traduzido

27,5%

Melhor EX no DATASUS

Dados reais de hospitalizações

Queda relativa superior a 60%

Três fatores discutidos no artigo

- (i) maior complexidade estrutural no DATASUS (média de 15 tabelas por banco); (ii) vocabulário técnico de domínio; (iii) uso integral do português no esquema e nos dados.

07 - Análise por dificuldade

Spider (dev)

86,5% → 39,2%

Qwen2.5-Coder-32B
fácil → extra-difícil

DATASUS (SIH/SUS)

64,7% → 6,7%

Qwen2.5-Coder-14B
fácil → difícil

Observa-se uma degradação sistemática de desempenho à medida que a complexidade aumenta; esse comportamento é particularmente acentuado em cenários mais desafiadores.

No DATASUS, nenhum modelo ultrapassa 10,5% de EX na dificuldade média e praticamente não há acertos em consultas difíceis.

1 **Avaliações em benchmarks tradicionais superestimam desempenho**

O gap entre cenários tradicionais e reais indica que avaliações baseadas em benchmarks isolados podem superestimar sistematicamente a capacidade dos modelos.

2 **O principal gargalo é a generalização composicional**

A diferença consistente entre CM e EX mostra que os modelos identificam componentes individuais, mas falham em compô-los em consultas executáveis.

3 **Especialização em código é insuficiente em cenários reais**

Modelos especializados apresentam ganhos em geração estrutural, mas esses ganhos diminuem em bases mais complexas; o alinhamento semântico passa a ser o fator limitante.

Cenários reais permanecem um desafio em aberto.

Text-to-SQL em português é fortemente dependente do cenário

C1

O benchmark unificado evidencia dependência do domínio, da estrutura do esquema e do alinhamento linguístico.

Há um gap substancial e sistemático entre benchmarks e cenários reais

C2

Modelos superam 65% de EX no Spider, mas não ultrapassam 27,5% no DATASUS; avaliações isoladas podem superestimar significativamente sua capacidade.

O principal gargalo é a generalização composicional e o alinhamento semântico

C3

O desafio central é menos sobre “gerar SQL” e mais sobre “compreender e estruturar corretamente a informação”.

Trabalhos Futuros: expandir o benchmark com novas bases em português • avaliar modelos proprietários • investigar prompting e raciocínio avançados • conduzir avaliações qualitativas dos erros

OBRIGADO!

Guilherme Fonseca

UFMG • Mestrando em Ciência da
Computação



LinkedIn



Artigo (SBBD 2026)



Agradecimentos: INCT-TILDIAR (408490/2024-1) • CAPES • FAPEMIG • Dadosfera • Embrapii • SEBRAE • NVIDIA