



8 a 11 de Setembro
São Carlos, SP - Brasil

PAIRS

Um Pipeline para Geração Automática e Curadoria de Benchmarks Text-to-SQL

**Eduardo C. da Camara^{*1}, Jaide F. C. Zardin^{*1}, Yago Lobato¹, Guilherme Fonseca³,
Matheus Botelho³, Emerson A. Simoes³, Lucas R. Silva³, Pedro Calais³, Rodrigo
Gonçalves³, Gustavo Ribeiro³, Allan Sene⁴, Julio C. S. Reis², Marcos André
Gonçalves³, Altigran da Silva¹**

¹Universidade Federal do Amazonas (UFAM), ²Universidade Federal de Viçosa (UFV),

³Universidade Federal de Minas Gerais (UFMG), ⁴Dadosfera Brasil {eduardo.camara, jaide.zardin}@icomp.ufam.edu.br



1. INTRODUÇÃO

- **Contexto:** Sistemas Text-to-SQL baseados em LLMs estão democratizando o acesso a dados;
- **Problema:** Os benchmarks públicos atuais não refletem a complexidade de bancos do mundo real (quantidade de tabelas, linguagem ambígua, etc.);
- **Solução (PAIRS):** Um pipeline para geração e curadoria de benchmarks Text-to-SQL voltados para domínios específicos;
- **Diferencial:** Geração guiada por **personas**. Em vez de apenas focar em variações sintáticas genéricas, o **PAIRS** ancora a linguagem a perfis que simulam os usuários reais do sistema. Garante diversidade nas perguntas, além de consistência das consultas em SQL e na intenção das perguntas em linguagem natural.

2. ARQUITETURA




Figura 1: Descrição do Pipeline do PAIRS

3. INTERFACE




Figura 2: Registro de Personas

4. RESULTADOS E CONCLUSÃO

- **Estudo de Caso:** Domínio da saúde pública brasileira utilizando bases do DataSUS.
- **Gerações por Etapa:**
 - 23 consultas SQL geradas;
 - 3 personas registradas (Cidadã Leiga, Analista de Dados, Gestor);
 - 195 pares (Pergunta, SQL) aprovados, com **94%** de taxa de aproveitamento.
- **Métricas de Avaliação:**
 - **Curadoria (Kappa de Fleiss = 0,50):** concordância moderada entre os avaliadores;
 - **Diversidade Sintática (BLEU = 0,50):** alta variabilidade na geração de paráfrases;
 - **Preservação Semântica (SBERT = 0,92):** conservação das intenções originais das perguntas.
- **Trabalhos Futuros:** avaliar o *PAIRS* em outros domínios; padronização de dificuldades das consultas; padronização da avaliação dos pares; avaliação de LLM-as-a-Judge e estratégias de exploração de dados.

5. REFERÊNCIAS

- [1] Coelho, Gustavo M. C., et al. "Improving the Accuracy of Text-to-SQL Tools Based on Large Language Models for Real-World Relational Databases." *Database and Expert Systems Applications*, pp. 93-107, 2024.
- [2] Li, Haoyang, et al. "CodeS: Towards Building Open-source Language Models for Text-to-SQL." *Proc. ACM Manag. Data*, vol. 2, no. 3, Article 127, 2024.
- [3] Dragusin, Catalina, et al. "Grounding LLMs for database exploration: Intent scoping and paraphrasing for robust NL2SQL." *Proceedings of the VLDB Endowment*, p. 8097, 2025.
- [4] Khalifat, N. "SynthSQL: A Framework for Generating Synthetic Text-to-SQL Datasets with Controlled Complexity." Technical Report, University of Alberta, 2025.
- [5] Fonseca, Guilherme, et al. "Avaliação Sistemática de Text-to-SQL em Português: Um Benchmark Unificado Multi-Domínio." *Anais do Simpósio Brasileiro de Banco de Dados (SBBDD)*, 2026.

APOIO:



dadosfera

