

# TEXT-TO-SQL NA ERA DOS GRANDES MODELOS DE LINGUAGEM

Fundamentos, Avaliação e o Cenário  
Brasileiro

---

**UFMG:** Guilherme Fonseca, Matheus Botelho, Lucas R. Silva, Emerson A. Simões, Pedro Calais, Rodrigo Gonçalves, Gustavo Ribeiro, Marcos André Gonçalves

**UFV:** Julio C. S. Reis


**UFAM:** Eduardo Camara, Jaide Zardin, Yago Lobato, Altigran da Silva

**Dadosfera Brasil:** Allan Sene



# NOSSA EQUIPE

Um projeto conjunto entre UFMG, UFAM e Dadosfera Brasil



Guilherme Fonseca  
do Nascimento




Matheus Botelho




Eduardo Câmara



Jaide Zardin



Lucas R. Silva



Emerson A. Simões



Pedro Calais



Rodrigo Gonçalves



Gustavo Ribeiro



Yago Lobato



Allan Sene



Julio C. S. Reis



Altigran da Silva



Marcos André Gonçalves

# SUMÁRIO

1

## Evolução do Text-to-SQL

Da era das regras e templates aos modelos de linguagem

2

## Abordagens Modernas

Prompting, RAG, schema linking e sistemas agênticos

3

## Métricas de Avaliação

Métricas estruturais e baseadas em execução

4

## Benchmarks Tradicionais e Cenários Reais

Spider, BIRD, Spider 2.0 e benchmarks empresariais

5

## Text-to-SQL em Português

Panorama e recursos para a língua portuguesa



# 01

## EVOLUÇÃO DO TEXT-TO-SQL

Da era das regras e templates aos modelos de linguagem



# POR QUE TEXT-TO-SQL IMPORTA?

A barreira de acesso aos dados ainda é técnica

## O cenário que motiva a tarefa

Dados de governos, empresas e aplicações crescem rapidamente, mas a consulta estruturada continua exigindo conhecimento técnico.

Tese da seção: democratizar acesso não é só gerar SQL; é alinhar intenção, esquema e domínio.

1

**dados crescem**

2

**SQL vira gargalo**

3

**usuário depende de especialista**

Text-to-SQL tenta reduzir essa barreira: o usuário pergunta em linguagem natural e o sistema produz a consulta executável.

# DEFINIÇÃO OPERACIONAL

Pergunta em linguagem natural + esquema → SQL executável

## Exemplo simples

### Pergunta

“Quais municípios  
tiveram mais internações  
em 2023?”

### Esquema

SIH\_RD

- MUNIC\_RES
- ANO\_CMPT
- QT\_INTERNAÇÕES

```
SELECT municipio, COUNT(*)  
  FROM internacoes  
 WHERE ano = 2023  
 GROUP BY municipio  
 ORDER BY COUNT(*) DESC;
```

A dificuldade é que a consulta correta depende de três coisas ao mesmo tempo: entender a intenção do usuário, localizar os elementos certos no esquema e escolher uma forma SQL executável e semanticamente equivalente.

# POR QUE A TAREFA É DIFÍCIL?

A linguagem é flexível; o banco é formal e relacional

## Do lado da linguagem

- sinônimos: “cidade”, “município”, “localidade”
- expressões vagas: “até”, “maior”, “recentes”
- perguntas incompletas ou dependentes de contexto
- termos de domínio que não aparecem literalmente no banco

SQL  
correto

## Do lado do banco

- nomes técnicos de colunas e códigos
- chaves, joins e cardinalidades
- dialetos SQL e funções específicas
- esquemas grandes com tabelas parecidas

# PRIMEIRA GERAÇÃO: SISTEMAS SIMBÓLICOS

LUNAR, CHAT-80 e PRECISE exemplificam a lógica de regras e gramáticas

Três famílias históricas ajudam a entender a primeira geração

1973

## LUNAR

interface para dados de geologia lunar; vocabulário e regras do domínio

1982

## CHAT-80

gramática em Prolog para consultas geográficas; tradução para lógica

2003

## PRECISE

mapeamento de tokens da pergunta para atributos/valores em perguntas “semanticamente tratáveis”

Ideia comum: o sistema sabe de antemão como palavras, relações e estruturas da pergunta devem virar uma consulta.

# COMO ERAM AS REGRAS?

Léxicos, gramáticas e templates transformavam padrões de fala em consultas

## Exemplo de léxico

```
'vendas'          →  
    DEPARTMENT.name  
'funcionários' → EMPLOYEE  
'trabalham em' →  
    EMPLOYEE.dept_id =  
    DEPARTMENT.id
```

## Exemplo de template

```
Quem trabalha em <departamento>?  
    → SELECT e.name  
FROM employee e JOIN department d  
    ON e.dept_id = d.id  
WHERE d.name = <departamento>;
```

## Vantagem

Alto controle quando o domínio, o vocabulário e os padrões de pergunta são conhecidos.


## Limitação

Baixa portabilidade: novo banco, novo vocabulário ou nova pergunta exigem novas regras.

# SEGUNDA GERAÇÃO: MODELOS NEURAIS

Seq2SQL, SQLNet e RAT-SQL deslocam o conhecimento para dados e representações

O avanço neural muda o que precisa ser escrito à mão



A promessa passa a ser generalização por aprendizado. O custo: depender de benchmarks grandes e ainda sofrer quando o esquema/domínio muda.

# BENCHMARKS MUDARAM A ÁREA

WikiSQL e Spider consolidaram avaliação supervisionada e cross-domain

Cada benchmark trouxe uma pergunta de pesquisa dominante

## WikiSQL

**escala em tabelas simples**

80k+ pares; uma tabela por consulta; impulsionou modelos supervisionados

## Spider

**cross-domain e SQL complexo**

múltiplos bancos; avalia generalização para esquemas não vistos

## BIRD

**escala e realismo maior**

benchmark grande para LLMs; evidencia custo de schema/contexto

**Eles tornam os resultados comparáveis, mas também criam o risco de confundir desempenho no benchmark com capacidade em produção.**

# TERCEIRA GERAÇÃO: LLMS E O GAP REAL

Modelos maiores ajudam, mas benchmarks tradicionais ainda superestimam cenários reais

A era dos LLMs não elimina a tensão entre benchmark e uso real

## Benchmark tradicional

perguntas curadas  
esquemas estáveis  
avaliação padronizada  
números altos em modelos recentes

## Cenário real

workflows empresariais  
esquemas grandes/dinâmicos  
valores e regras de domínio  
falhas severas mesmo com LLMs

Em Spider 2.0, mesmo o estado da arte resolve 21,3% das tarefas, contra 91,2% no Spider 1.0.

# 02

---

## ABORDAGENS MODERNAS


Prompting, RAG, schema linking e sistemas  
agênticos



# DO ZERO-SHOT AO SISTEMA COMPLETO

LLM sozinho raramente é a arquitetura inteira

A arquitetura moderna adiciona componentes ao redor do gerador



Prompting define a tarefa

RAG/schema linking reduzem ruído

execução alimenta refinamento

Pergunta-guia da seção: que componente resolve qual problema — e que novo risco ele introduz?

# PROMPTING: ANATOMIA DA INSTRUÇÃO

O prompt define tarefa, contexto, restrições e formato da saída

Você é um especialista em PostgreSQL.

Tarefa: gere apenas uma consulta SQL.

Esquema relevante:

Tabela internacoes(cod\_municipio, ano, cid,  
valor)

Pergunta:

Quais municípios tiveram mais internações em  
2023?

Restrições:

- não explique;
- use apenas colunas do esquema;
- retorne SQL válido.

## O que o prompt controla?


- papel do modelo e dialeto SQL
- recorte do esquema e documentação
- formato exato da resposta
- regras de segurança e validação

Gao et al. estudam sistematicamente representações da pergunta, componentes de prompt e organização de exemplos.

# DECOMPOSIÇÃO: DIN-SQL

Dividir a tarefa em módulos reduz o peso de uma geração direta

DIN-SQL é um exemplo de prompting decomposto para Text-to-SQL




Exemplo de decomposição: “liste hospitais com maior valor médio” → identificar entidade hospital, métrica AVG(valor), agrupamento por hospital e ordenação desc.

# FEW-SHOT: DAIL-SQL

Exemplos semelhantes ensinam padrões de pergunta e esqueleto SQL

Few-shot não é só “colocar exemplos”: a seleção dos exemplos faz parte do método




Exemplo recuperado: “internações por ano” → `SELECT ano, COUNT(*) ... GROUP BY ano`

A intuição é ensinar o padrão estrutural certo sem treinar novamente o modelo.

# RAG: DOCUMENTAÇÃO E EXEMPLOS

Recuperar contexto antes de gerar reduz dependência de memória paramétrica

RAG troca “decorar tudo no modelo” por recuperar evidências do domínio



Em Text-to-SQL, a recuperação costuma trazer significado de colunas, exemplos de consultas e regras de negócio que não aparecem no nome do atributo.

# REPRESENTAÇÃO DO ESQUEMA

A forma como o banco é mostrado ao modelo muda o resultado

O mesmo banco pode ser apresentado de formas muito diferentes

```
CREATE TABLE SIH_RD(  
  MUNIC_RES INT,  
  ANO_CMPT INT,  
  VAL_TOT DECIMAL  
);
```

## Descrição em LN

“MUNIC\_RES identifica o município de residência do paciente.”

## View para LLM


internacoes\_por\_municipio(  
municipio, ano, total )

RAT-SQL tratava relações do esquema dentro do encoder neural. Na era dos LLMs, a mesma preocupação reaparece como DDL, descrições, views, amostras de valores e M-Schema.

# SCHEMA LINKING

Selecionar tabelas e colunas relevantes antes da geração

Schema linking é o filtro entre pergunta e esquema completo



# VALORES E VOCABULÁRIO DE DOMÍNIO

Muitos erros vêm do alinhamento semântico, não da sintaxe SQL

Domínios reais usam vocabulário de negócio, códigos e abreviações




Por isso, documentação, amostras de valores e exemplos do domínio podem importar mais do que apenas “saber SQL”.

# VALIDAÇÃO POR EXECUÇÃO E REFINAMENTO

O erro do banco vira sinal para corrigir a consulta

Sistemas modernos usam o próprio banco como fonte de feedback




O refinamento ajuda quando o SQL falha por erro sintático ou referência inexistente; não resolve automaticamente intenção mal compreendida.

# SISTEMAS AGÊNTICOS: MAC-SQL

Três papéis especializados colaboram na geração da consulta

MAC-SQL organiza a tarefa em três agentes principais




A diferença para uma geração direta é que cada agente tem uma responsabilidade clara e pode usar ferramentas/modelos auxiliares.

# PIPELINE MODERNO DE TEXT-TO-SQL

Os componentes aparecem combinados em sistemas práticos

Uma arquitetura real mistura técnicas; não escolhe apenas uma



# O QUE FICA PARA A PRÁTICA?

Estratégias modernas viram escolhas experimentais e decisões de engenharia

cada componente vira uma escolha experimental concreta

## Contexto

esquema completo • descrições • documentação • exemplos • valores

## Método

zero-shot • few-shot • RAG • decomposição • agentes • refinamento

## Avaliação

EX • CM • métricas suaves • análise humana • erro por classe/domínio

# 03

---

## MÉTRICAS DE AVALIAÇÃO

Métricas estruturais e baseadas em  
execução



# Limitações das Métricas Tradicionais

## Invariáveis e binárias



São adequadas para *benchmarks* controlados, mas falham ao refletir a incerteza e a complexidade da linguagem natural assim como dos repositórios de dados e usuários do mundo real.

# Exemplos

## Conversão linguagem natural-matemática

Pergunta: Me mostre os produtos que vencem **até** o dia 31/12/2024.

SQL GOLD

```
SELECT
    ...
WHERE
    data_de_validade <= '2024-12-31'
```



SQL Gerado

```
SELECT
    ...
WHERE
    data_de_validade < '2024-12-31'
```

Qual a maneira correta de representar “até” em linguagem matemática?

Todo usuário saberia a maneira mais formal?

# Exemplos

## Outras divergências

Pergunta: Liste as instituições com mais medicamentos com estoque de produtos entre 1 a 5 unidades.

SQL GOLD

SELECT

...

WHERE

quantidade BETWEEN 1 AND 5

AND instituicao\_id IS NOT NULL



SQL Gerado

SELECT

...

WHERE


quantidade BETWEEN 1 AND 5

O resultado do SQL é diferente, mas a pergunta do usuário foi respondida?

Deveríamos considerar que o SQL Gerado foi incorreto de maneira binária?

# Métricas de Execução

## Avaliam os dados




## Exemplos

- Execution Accuracy (EX)
- SOFT-F1 Score
- Statistical Summarization
- Similarity Scoring
- Query Affinity Score

Estas métricas avaliam se os dados retornados pela consulta gerada por LLM são equivalentes aos dados retornados pelo SQL Gold.

# Métricas de Sintaxe

## Avaliam o SQL



### Exemplos

-  Component Match (CM)
-  Exact Match (EM)
-  Logical-Form Accuracy
-  Levenshtein Correctness
-  Query Affinity Score

Estas métricas avaliam se o SQL gerado pela LLM é equivalente ao SQL Gold. Não necessita de compilação do banco.

# Avaliações das Métricas

## Aproximação de um avaliador humano

Kappa de Cohen das Métricas no dataset do DATASUS

87,9%



SOFT-F1 Score

85,2%



Query Affinity Score

76,3%



Levenshtein Correctness

74,0%



Execution Accuracy

- O **Kappa de Cohen** nos permite avaliar a coerência entre as métricas e a avaliação **humana**, identificando as métricas que lidam melhor com incertezas.
- Métricas **híbridas** (de sintaxe e de execução) podem ser úteis para obter uma melhor avaliação do SQL.
- Métricas mais **suaves** tendem a concordar mais com avaliadores humanos.

# 04

---

## BENCHMARKS TRADICIONAIS E CENÁRIOS REAIS

Spider, BIRD, Spider 2.0 e benchmarks  
empresariais



# Benchmarks

2017



**WikiSQL**

Uma tabela, sem JOIN.  
Escala grande, estrutura simples.

2018



**Spider**

10.181 perguntas no conjunto original, 200 bancos, 138 domínios.  
Generalização para bancos novos.

2023



**BIRD**

12.751 pares, 95 bancos.  
Conhecimento externo e eficiência da consulta.

2025



**Spider 2.0**

632 tarefas de fluxo real.  
Esquemas com +1.000 colunas e vários dialetos SQL.

# Benchmarks

Benchmark Text-to-SQL e o que é colocado sob pressão

| Benchmark                           | Origem do banco                  | O que coloca sob pressão                       | Onde é frágil                         |
|-------------------------------------|----------------------------------|------------------------------------------------|---------------------------------------|
| <b>Spider</b>                       | montado para o benchmark         | generalização para esquemas não vistos         | esquemas limpos e pequenos            |
| <b>BIRD</b>                         | bases públicas reais             | conhecimento externo e eficiência da consulta  | pergunta ainda autocontida            |
| <b>Spider 2.0</b>                   | ambientes empresariais           | escala do esquema, dialeto e fluxo de trabalho | poucos exemplos, custo alto           |
| <b>BEAVER</b>                       | logs de data warehouses privados | esquema corporativo e pergunta de negócio      | dados não podem ser abertos           |
| <b>Domínio (saúde, jurídico...)</b> | sistemas em produção             | vocabulário técnico e dado incompleto          | números não comparáveis entre estudos |

Fontes: Yu et al. (2018); Li et al. (2023); Lei et al. (2025); Chen et al., BEAVER (2024); EHRSQL (NeurIPS 2022).

# Benchmarks

Dificuldades de adaptar bancos para a tarefa do benchmark

---

- 1 Escala e nomeação do esquema**

Centenas de tabelas e colunas com nomes de difícil compreensão herdados do sistema de origem.
- 2 Integração entre fontes**

O JOIN correto depende de uma chave que ninguém documentou e que às vezes não casa.
- 3 Incompletude**

Nulos e registros parciais mudam o resultado de qualquer agregação.
- 4 Conhecimento tácito**

Regras de negócio e siglas que não estão no DDL nem na pergunta.
- 5 Ambiguidade da pergunta**

O usuário real pergunta menos do que precisa; o gold vira uma decisão de interpretação.

# Construir Um Benchmark De Cenário Real

A origem dos pares pergunta/SQL define o que o benchmark consegue provar

## A partir de logs de produção

*BEAVER e similares*

### O que ganha

- consulta escrita por quem tinha a necessidade real
- distribuição de perguntas fiel ao uso
- escala: milhares de pares de uma vez

### O que custa

- depende de acesso a logs privados
- raramente pode ser publicado
- a pergunta em linguagem natural precisa ser reconstruída depois

## A partir de uma base pública real

*JABUTI-SQL e similares*

### O que ganha

- reprodutível e citável por qualquer grupo
- controle sobre dificuldade e perfil de usuário
- o ruído da base é preservado de propósito

### O que custa

- dificuldade para obter volume de pares
- a pergunta é sintetizada, não observada
- curadoria manual custa caro

# Um Caso Concreto

JABUTI-SQL: o que a base real impôs ao processo de construção

5

bases do DATASUS  
integradas

143M

registros no  
esquema unificado

44%

de nulos no campo mais afetado,  
preservados

69

pares pergunta/SQL  
curados, 3 personas

## Três escolhas que o cenário real forçou

### Integrar antes de perguntar

Sem um esquema unificado, cada fonte responderia a uma pergunta diferente sobre a mesma entidade.

### Não limpar o que é característico

A incompletude é o fenômeno a ser medido, não um defeito do dado.

### Estratificar por perfil de usuário

A mesma consulta muda de dificuldade conforme quem formula a pergunta.

**Curar isso à mão não escala — e é exatamente esse o problema que o PAIRS ataca, a seguir.**

# Da Origem dos Dados ao Processo de Geração

## Contextualização dos sistemas de geração de benchmarks

### CodeS

*Li et al., 2024*

#### Ponto de partida

Parte de instâncias/templates existentes

#### O que faz

Usa LLMs para paráfrase de perguntas e preenchimento dos templates

#### Limitação

Tende a baixa variabilidade semântica (repetitivo)

# Da Origem dos Dados ao Processo de Geração

## Contextualização dos sistemas de geração de benchmarks

### CodeS

*Li et al., 2024*

#### Ponto de partida

Parte de instâncias/templates existentes

#### O que faz

Usa LLMs para paráfrase de perguntas e preenchimento dos templates

#### Limitação

Tende a baixa variabilidade semântica (repetitivo)

### Coelho et al.

*DEXA, 2024*

#### Ponto de partida

Parte de colunas selecionadas para a geração

#### O que faz

Gera perguntas a partir das colunas para converter para SQL

#### Limitação

Depende de dados prévios de uso da base de dados

# Da Origem dos Dados ao Processo de Geração

## Contextualização dos sistemas de geração de benchmarks

### CodeS

*Li et al., 2024*

#### Ponto de partida

Parte de instâncias/templates existentes

#### O que faz

Usa LLMs para paráfrase de perguntas e preenchimento dos templates

#### Limitação

Tende a baixa variabilidade semântica (repetitivo)

### Coelho et al.

*DEXA, 2024*

#### Ponto de partida

Parte de colunas selecionadas para a geração

#### O que faz

Gera perguntas a partir das colunas para converter para SQL

#### Limitação

Depende de dados prévios de uso da base de dados

### Dragusin et al.

*VLDB, 2025*

#### Ponto de partida

Reconhecimento de entidades para extração de intenção

#### O que faz

Aumento de contexto das perguntas para geração de paráfrases

#### Limitação

É construída a partir de uma base prévia de pares

# Da Origem dos Dados ao Processo de Geração

## Contextualização dos sistemas de geração de benchmarks

### CodeS

*Li et al., 2024*

#### Ponto de partida

Pares já existentes / templates de sql disponíveis

#### O que faz

Usa LLMs para paráfrase de perguntas / preenchimento dos templates

#### Limitação

Tende a baixa variabilidade semântica (repetitivo)

### Coelho et al.

*DEXA, 2024*

#### Ponto de partida

Parte de colunas selecionadas para a geração

#### O que faz

Gera perguntas a partir das colunas para converter para SQL

#### Limitação

Depende de dados prévios de uso da base de dados

### Dragusin et al.

*VLDB, 2025*

#### Ponto de partida

Reconhecimento de entidades para extração de intenção

#### O que faz

Aumento de contexto das perguntas para geração de paráfrases

#### Limitação

É construída a partir de uma base prévia de pares

### SynthSQL

*Khalifat, 2025*

#### Ponto de partida

Parte da construção de consultas SQL

#### O que faz

Estratégia de *back-translation* para converter os SQLs em linguagem natural

#### Limitação

Não há variabilidade na construção das perguntas

# PAIRS

## Pipeline de Geração de Pares LN-SQL



### Geração Automatizada e Validada

Lê a estrutura DDL e gera consultas SQL válidas, corrigindo erros de forma autônoma sem esforço humano inicial

### Diferencial: Personas de Linguagem Natural

Sintetiza perguntas baseadas em perfis (médico vs. leigo), garantindo que a IA entenda o vocabulário real de todos os usuários

### Garantia de Qualidade (Human-in-the-loop)


Possibilidade de especialistas revisarem e aprovarem os pares gerados, unindo a rapidez com a precisão humana

# Comparação entre as Abordagens

| Característica                       | Coelho et al. | CodeS | Dragusin et al. | SynthSQL | PAIRS |
|--------------------------------------|---------------|-------|-----------------|----------|-------|
| Geração automática de perguntas (NL) | ●             | ●     | ●               | ●        | ●     |
| Geração automática de SQL            | ●             | ●     | ⊖               | ●        | ●     |
| Curadoria manual e correção          | ⊖             | ○     | ○               | ○        | ●     |
| Geração de paráfrases                | ○             | ●     | ●               | ○        | ●     |
| Controle de complexidade             | ⊖             | ○     | ○               | ●        | ●     |
| Módulo de correção automática de SQL | ○             | ○     | ●               | ●        | ⊖     |
| Perfis de usuário (personas)         | ○             | ○     | ○               | ○        | ●     |

● suporte completo   ⊖ suporte parcial   ○ ausente

# Pipeline



# Um SQL para várias perguntas



## Cidadã Leiga

Sem formação técnica: vocabulário simples e sem conhecimento do esquema

*"Quantos hospitais estão funcionando por tipo de administração? Mostra os que têm mais primeiro"*



## Gestor Hospitalar

Domina terminologia do SUS, mas sem conhecimento técnico em banco de dados.

*"Qual a quantidade de instituições de saúde ativas por tipo de gestão, apresentadas do tipo com maior número de unidades para o menor?"*


```
SELECT tipo_de_gestao,  
       COUNT(*) AS total_instituicoes  
FROM instituicao  
WHERE motivo_da_desabilitacao IS NULL  
GROUP BY tipo_de_gestao  
ORDER BY total_instituicoes DESC;
```

# Como Usar

## Interface Web



<https://github.com/Dadosfera-DCC-UFGM/PAIRS>



# Para o que o PAIRS serve

---



## **Agnóstico a domínio**

Opera sobre qualquer banco relacional a partir do esquema, sem depender de dados previamente rotulados

# Para o que o PAIRS serve



## Agnóstico a domínio

Opera sobre qualquer banco relacional a partir do esquema, sem depender de dados previamente rotulados



## Construção de benchmarks

Gera pares pergunta-SQL curados para avaliar sistemas Text-to-SQL no domínio específico do dataset

# Para o que o PAIRS serve



## Agnóstico a domínio

Opera sobre qualquer banco relacional a partir do esquema, sem depender de dados previamente rotulados



## Construção de benchmarks

Gera pares pergunta-SQL curados para avaliar sistemas Text-to-SQL no domínio específico do dataset



## Aumento de dados

Produz dados de treinamento com diversidade linguística, para fine-tuning de modelos de linguagem

# Estudo de Caso

## Validando o pipeline



### Dataset escolhido

Domínio da saúde pública brasileira utilizando bases do DataSUS

## Gerações por cada etapa



**23 consultas SQL** geradas, com diferentes níveis de dificuldade



**3 personas** registradas (Cidadã Leiga, Analista de Dados, Gestor)



**195 pares** (Pergunta, SQL) de 207 aprovados

# Estudo de Caso

## Validando o pipeline



### Dataset escolhido

Domínio da saúde pública  
brasileira utilizando bases do  
DataSUS

## Métricas de Avaliação




**Kappa Fleiss = 0,50:**

concordância moderada entre os  
avaliadores



**BLEU = 0,50:** alta variabilidade na  
geração de paráfrases



**SBERT = 0,92:** conservação das  
intenções originais das perguntas

# Dificuldade das consultas

## Instruções passadas para o LLM

### Simple

Critérios obrigatórios:

- Envolve no máximo 1 tabela
- Sem JOINS
- Sem subconsultas ou CTEs
- Agregações permitidas (com ou sem HAVING)

### Médio

Critérios (aplicar ao menos 2):

- Entre 2 e 3 tabelas via JOIN (INNER, LEFT ou RIGHT)
- Agregações com HAVING
- Uma subconsulta simples (não correlacionada) ou uma CTE
- Funções de janela (ROW\_NUMBER, RANK, DENSE\_RANK) sem partições aninhadas

### Difícil

Critérios (aplicar ao menos 2):

- 4 ou mais tabelas via JOIN
- Uma CTE ou mais encadeadas ou subconsultas correlacionadas
- Funções de janela com PARTITION BY e ORDER BY combinados
- Lógica condicional complexa (CASE WHEN ou múltiplos critérios)
- Operações de conjunto (UNION, INTERSECT, EXCEPT)
- Auto-joins ou joins com subqueries no ON

# 05


## TEXT-TO-SQL EM PORTUGUÊS

Panorama e recursos para a língua  
portuguesa



# A TRAJETÓRIA DO TEXT-TO-SQL EM PORTUGUÊS

A área passou de adaptações do Spider a estudos com LLMs, domínios nacionais e avaliações controladas



# BENCHMARK TRADUZIDO $\neq$ CENÁRIO BRASILEIRO

As duas linhas são complementares, mas respondem perguntas de avaliação distintas

## BENCHMARK TRADUZIDO

Spider-pt / BIRD\_PT / MultiSpider 2.0

- facilita comparar idiomas e modelos
- preserva parte da estrutura original
- herda limitações do benchmark de origem

## CENÁRIO DE DOMÍNIO

text2SQL4PM / DATASUS /  
AtlasSQL-BR

- traz vocabulário e regras do domínio
- inclui dados brasileiros reais
- aumenta realismo, mas dificulta comparação direta

# O IDIOMA MUDA O DESEMPENHO

BIRD\_PT mantém esquema e valores em inglês, mas muda perguntas e conhecimento externo para português

Acurácia média reportada por modelo em BIRD (EN) e BIRD\_PT (PT)

## Gemini 2.5 Pro

EN

PT

**62.3%** **61.5%**

-0,8 pp

## Qwen3-Next

EN

PT

**61.4%** **58.7%**

-2,6 pp

## DeepSeek R1

EN

PT

**50.0%** **25.1%**

-24,9 pp

Na média, todos os modelos avaliados perdem acurácia ao passar do inglês para o português; a magnitude da queda depende do modelo.

# NÃO BASTA TRADUZIR A PERGUNTA

Um estudo em PT-BR isolou o schema linking antes da geração do SQL

Qwen2.5-Coder-32B + BGE-M3 — Spider-pt (Dev)



A forma de representar o esquema afeta a recuperação do banco correto — e, portanto, a geração final do SQL.

# ECOSSISTEMA EM PT: DOMÍNIOS DIVERSOS

Os recursos existentes variam em origem, domínio e grau de “português” no banco

| Recurso         | Domínio                  | Escala / recorte                | Característica                          |
|-----------------|--------------------------|---------------------------------|-----------------------------------------|
| Spider-pt       | benchmark traduzido      | 1.034 dev + 2.147 test          | perguntas em PT; estrutura Spider 1.0   |
| MultiSpider 2.0 | multilíngue / enterprise | 5.056 exemplos; 632 em PT       | Spider 2.0 em 8 idiomas                 |
| text2SQL4PM     | process mining           | 1.655 enunciados / 205 SQL      | recurso bilíngue PT-EN                  |
| DATASUS         | hospitalizações          | 51 pares no benchmark unificado | esquema e dados brasileiros             |
| AtlasSQL-BR     | geoespacial              | recurso em PT-BR                | hierarquias territoriais e SQL espacial |

**A diversidade ajuda a testar generalização, mas números de estudos diferentes não são diretamente comparáveis.**

# O PANORAMA EM PORTUGUÊS VAI ALÉM DAS BASES

Há estudos sobre sistemas completos, agentes, idioma, tempo e schema linking

## Sistema completo em PT

José et al. (PROPOR 2022)

QA neural + Text-to-SQL, com seleção automática do módulo.

## Agente + feedback

Petrola et al. (SBBD 2025)

Agente modular com DeepSeek, ciclos de feedback e reescrita heurística.

## Idioma e tradução

Nobre et al. (PROPOR 2026)

BIRD\_PT mostra queda de acurácia ao trocar EN por PT.

## Schema linking

Kreitlow & Oliveira (PROPOR 2026)

Descrições em linguagem natural superam DDL/DML na recuperação do banco correto.

# Metodologias diferentes

1

## Spider-pt

Pedroso et al. (2025)

tradução validada do  
Spider  
avaliação de diferentes  
LLMs

2

## text2SQL4PM

Yamate et al. (2025)

domínio de process  
mining  
baseline com GPT-3.5  
Turbo

3

## DATASUS


Moraes et al. (2025)

hospitalizações / 52  
consultas  
LangGraph + Llama 3.1  
+ autocorreção

Comparar números diretamente mistura efeito do idioma, do domínio, do modelo e do método.

# POR QUE UNIFICAR A AVALIAÇÃO?

Estudo de caso: benchmark unificado multi-domínio em português — SBBD 2026



# QUATRO CONJUNTOS, PERFIS DIFERENTES

O benchmark combina versões traduzidas do Spider com dois domínios específicos

| Base              | Contexto                       | # pares | # BDs | Média de tabelas |
|-------------------|--------------------------------|---------|-------|------------------|
| Spider-pt (dev)   | tradução do dev do Spider 1.0  | 1.034   | 20    | 4,00 ± 2,50      |
| Spider-pt (test)  | tradução do test do Spider 1.0 | 2.147   | 40    | 4,50 ± 2,88      |
| text2SQL4PM       | pagamentos e requerimentos     | 1.655   | 1     | 6                |
| DATASUS (SIH/SUS) | dados de hospitalizações       | 51      | 1     | 15               |

DATASUS é a única das quatro bases inteiramente em português; nas demais, perguntas em português convivem com esquema ou conteúdo em inglês.

# PROTOCOLO CONTROLADO

A ideia é mudar a base — não o método

## MODELOS

Qwen2.5-Coder-7B-Instruct  
Qwen2.5-Coder-14B-Instruct  
Qwen2.5-Coder-32B-Instruct  
Qwen2.5-32B-Instruct  
Llama-3.1-8B-Instruct  
Llama-3-sqlcoder-8b

## CONFIGURAÇÃO FIXA

### Quantização

4-bit NF4 / bfloat16

### Decodificação

greedy e determinística

### Prompting

zero-shot; esquema completo

### Idioma

instrução em inglês; pergunta em português


### Avaliação

EX e CM

Sem agentes, RAG, few-shot ou bibliotecas  
Text-to-SQL adicionais.

# O GAP ENTRE SPIDER E DATASUS É GRANDE

Melhor Acurácia de Execução (EX) observada em cada conjunto do benchmark




O melhor DATASUS é o Qwen2.5-Coder-14B; nos Spider, o 32B lidera.

queda relativa > 60%

# Modelos de CÓDIGO AJUDA, MAS TEM LIMITES

Comparação controlada: Qwen2.5-Coder-32B vs. Qwen2.5-32B




No DATASUS, o Coder-14B chega a 27,5% e supera o Coder-32B: mais parâmetros não garantiram o melhor resultado.


# A COMPLEXIDADE DERRUBA O DESEMPENHO

A degradação é muito mais severa no cenário real de saúde

## SPIDER-PT (DEV) — Qwen2.5-Coder-32B



## DATASUS — Qwen2.5-Coder-14B



No DATASUS, nenhum modelo passa de 10,5% nas consultas médias e praticamente não há acertos nas difíceis.

# TRÊS MENSAGENS PRINCIPAIS

O resultado central não é apenas um ranking de modelos

## 1 Spider não basta

70,7% no Spider-test contra 27,5% no DATASUS: desempenho de benchmark não se transfere automaticamente.

## 2 Componentes não garantem consulta correta

CM permanece relativamente alto quando EX cai, apontando limitações de generalização composicional.

## 3 Coder e escala ajudam, mas têm limite

A especialização em código melhora vários cenários, mas o ganho encolhe quando domínio e semântica dominam.

**Limitações: uma única configuração zero-shot • sem modelos proprietários de última geração • DATASUS com amostra pequena**

# Exemplo de Text-to-SQL



# OBRIGADO!

---



JABUTI-SQL



PAIRS



**Agradecimentos:** INCT-TILDIAR (408490/2024-1) • CAPES • FAPEMIG • Dadosfera • Embrapii • SEBRAE • NVIDIA